




Šimon Jukl & Michal Hužva

Odhadování počtu cest v grafech

Psychofyzikální experiment

květen 2026

Obsah


1	Úvod	3
2	Vlastnosti grafů a simulace	4
2.1	Stanovení rozsahů parametrů	4
3	Design	8
4	Deskriptivní statistika	9
4.1	Chybějící hodnoty	9
4.2	Rychlost odpovědi	10
4.3	Odpovědi	11
5	Modely	16
5.1	Model 1: Cesty a doba trvání	16
5.2	Model 2: Zero-truncated Poisson	17
5.3	Model 3: Varying effects	20
5.4	Model 4: Conway-Maxwell Poisson (COMP)	22
5.5	Model 5: Reziduály smyček	22
5.5.1	Implikace priorů	22
5.5.2	Fit	25
5.6	PSIS-LOO	30
6	Limitace	31

1 Úvod

V tomto experimentu měli participanti za úkol odhadovat, kolik unikátních cest viděli ve čtvercovém 4x4 neorientovaném grafu (viz Obrázek 1.1).

Obrázek 1.1

Příklad grafu



Grafy se lišily těmito parametry:

- počet cest (1, 7)
- počet hran (15, 19)
- počet smyček (0, 4)

2 Vlastnosti grafů a simulace

K prozkoumání vlastností grafů před administrací byly použity simulace.

V jednoduchém grafu, kde jsou všechny uzly spojeny pouze se sousedními uzly nediagonálně, může být maximálně

$$(x - 1) \cdot y + x \cdot (y - 1)$$

hran, kde x a y jsou počet řádek a sloupců (počet uzlů v každé dimenzi), což se pro čtvercový graf zjednoduší na

$$2 \cdot x \cdot (x - 1).$$

V našem případě pro graf o velikosti 4 je to tedy $2 \cdot 4 \cdot (4 - 1) = 24$.

Pro graf orientovaný, tedy s jednosměrnými spoji mezi uzly, by tento počet byl dvojnásobný.


Pokud jde o počet smyček, ten je v našem rozsahu plně determinován počtem hran. Minimální počet hran, kterým lze propojit graf, je 15, což implikuje absenci smyček, které vytvářejí nadbytečné spoje. Maximální počet hran, 19, koresponduje ke 4 smyčkám.

2.1 Stanovení rozsahů parametrů

Grafy byly generovány pomocí stanovení minimálního a maximálního počtu hran a cílového počtu cest v grafu.

Obrázek 2.1

Rozložení četnosti počtu hran podle cílového počtu cest




Obrázek 2.1 zobrazuje zásadní omezení, tedy že po překročení 19 hran začne minimální možný počet cest zásadně narůstat. Je nám tedy stanovena limitace na počet cest jako 7 a méně. Na základě pilotáže jsme usoudili, že pro krátce prezetované grafy stejně není vyšší počet cest vyhovující.

Na obrázcích níže lze vidět vztah cest s hranami (Obrázek 2.2) a smyčkami (Obrázek 2.3), respektive jejich ekvivalence.


Obrázek 2.2

Počet cest v závislosti na počtu hran



Obrázek 2.3

Počet smyček v závislosti na počtu cest



3 Design

- 10/20 trénovacích trialů
- 1, 3, 5 sekund prezentace stimulu
- 9 x 1 až 7 cest = 63 trialů ()
- 3 bloky x 63 trialů
- po prezentaci 5 s na odpověď

4 Deskriptivní statistika

4.1 Chybějící hodnoty

Viz Tabulka 4.1

Tabulka 4.1


Počet chybějících odpovědí podle doby trvání stimulu

ID	Block		
	1	2	3
01	0	0	1
02	0	0	0
03	0	0	0
04	0	0	0

4.2 Rychlost odpovědi

Obrázek 4.1


Rychlost odpovědi podle doby trvání stimulu



4.3 Odpovědi


Obrázek 4.2

Odpovědi podle reálného počtu cest



Obrázek 4.3


Správné odpovědi podle reálného počtu cest



Participant č. 1 vyplnil experiment 2krát.


Obrázek 4.4

Reakční čas podle odpovědi a doby trvání stimulu




Obrázek 4.5

Vztah odpovědí, počtu cest a doby trvání stimulu



Obrázek 4.6

Vztah odpovědí, počtu smyček a doby trvání stimulu



5 Modely

- Poissonova (log-lineární) regrese
- všechny prediktory jsou vycentrované
- y je odpověď participanta
- p je počet cest
- t je doba prezentace stimulu
- l je počet smyček

5.1 Model 1: Cesty a doba trvání

$$\begin{aligned}y_i &\sim \text{Poisson}(\lambda_i) \\ \log \lambda_i &= \beta_0 + \beta_p(p_i - \bar{p}) + \beta_t(t_i - \bar{t}) \\ \beta_0 &\sim \text{Normal}(\log \bar{p}, 0.2) \\ \beta_p &\sim \text{Normal}(0.1, 0.2) \\ \beta_t &\sim \text{Normal}(0, 0.1)\end{aligned}$$

Family: poisson

Links: mu = log

Formula: response ~ 0 + Intercept + p + t

Data: d (Number of observations: 888)

Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;

total post-warmup draws = 4000

Regression Coefficients:


	Estimate	Est.Error	1-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
Intercept	1.01	0.02	0.97	1.05	1.00	3248	3008
p	0.28	0.02	0.24	0.32	1.00	3502	2969
t	0.05	0.02	0.01	0.08	1.00	3960	2839

Draws were sampled using `sample(hmc)`. For each parameter, Bulk_ESS and Tail_ESS are effective sample size measures, and Rhat is the potential scale reduction factor on split chains (at convergence, Rhat = 1).

Model dovoluje nulu, což neodpovídá našim podmínkám.

Obrázek 5.1

Posteriorní predikce (tmavě) vs. reálná data (světlé sloupce)



5.2 Model 2: Zero-truncated Poisson

Všechny následující modely používají zero-truncated Poissonovu regresi, která omezuje možné odpovědi dolní hranicí na jedna a více, tedy nedovoluje nulu.

$$y_i \sim \text{ZTPoisson}(\lambda_i)$$

$$\log \lambda_i = \beta_0 + \beta_p(p_i - \bar{p}) + \beta_t(t_i - \bar{t})$$

$$\beta_0 \sim \text{Normal}(\log \bar{p}, 0.2)$$

$$\beta_p \sim \text{Normal}(0.1, 0.2)$$

$$\beta_t \sim \text{Normal}(0, 0.1)$$

Family: poisson

Links: mu = log

Formula: response | trunc(lb = 1) ~ 0 + Intercept + p + t

Data: d (Number of observations: 888)

Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;

total post-warmup draws = 4000

Regression Coefficients:


	Estimate	Est.Error	1-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
Intercept	0.90	0.02	0.85	0.95	1.00	2792	2852
p	0.36	0.02	0.31	0.40	1.00	3172	2816
t	0.06	0.02	0.01	0.10	1.00	3352	2580

Draws were sampled using `sample(hmc)`. For each parameter, `Bulk_ESS` and `Tail_ESS` are effective sample size measures, and `Rhat` is the potential scale reduction factor on split chains (at convergence, `Rhat` = 1).

Tento model pasuje o něco lépe, bohužel stále vidíme odchylky kvůli parametrizaci Poissonovy regrese, ve které je parametr λ jak očekávanou hodnotou, tak mírou rozptylu. Zde pak dochází k tomu, že aby model vyhověl rozptylu dat, snižuje λ , čímž však dostává očekávanou hodnotu pod reálný peak dat.

Obrázek 5.2

Posteriorní predikce (tmavě) vs. reálná data (světlé sloupce)



5.3 Model 3: Varying effects

$$\begin{aligned}
y_i &\sim \text{ZTPoisson}(\lambda_i) \\
\log \lambda_i &= \beta_0 + u_{0,\text{id}[i]} + (\beta_p + u_{p,\text{id}[i]})(p_i - \bar{p}) + (\beta_t + u_{t,\text{id}[i]})(t_i - \bar{t}) \\
\beta_0 &\sim \text{Normal}(\log \bar{p}, 0.2) \\
\beta_p &\sim \text{Normal}(0.1, 0.2) \\
\beta_t &\sim \text{Normal}(0, 0.1) \\
\begin{pmatrix} u_{0,j} \\ u_{p,j} \\ u_{t,j} \end{pmatrix} &\sim \text{MVNormal}(\mathbf{0}, \mathbf{S}) \\
\mathbf{S} &= \text{diag}(\sigma) \mathbf{R} \text{diag}(\sigma) \\
\sigma &\sim \text{Student-t}(3, 0, 0.2) \\
\mathbf{R} &\sim \text{LKJ}(2)
\end{aligned}$$

Family: poisson

Links: mu = log

Formula: response | trunc(lb = 1) ~ 0 + Intercept + p + t + (1 + p + t | id)

Data: d (Number of observations: 888)

Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;

total post-warmup draws = 4000

Multilevel Hyperparameters:

~id (Number of levels: 4)

	Estimate	Est.Error	l-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
sd(Intercept)	0.14	0.09	0.03	0.36	1.00	1409	1268
sd(p)	0.14	0.08	0.04	0.35	1.00	1530	1912
sd(t)	0.11	0.06	0.02	0.27	1.00	1855	1642
cor(Intercept,p)	-0.02	0.37	-0.69	0.66	1.00	2571	2656
cor(Intercept,t)	-0.30	0.37	-0.89	0.46	1.00	3136	2616
cor(p,t)	-0.02	0.36	-0.70	0.66	1.00	3249	3325

Regression Coefficients:


	Estimate	Est.Error	l-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
Intercept	0.94	0.08	0.80	1.14	1.00	1647	1699
p	0.33	0.08	0.14	0.46	1.00	1869	1904
t	0.05	0.05	-0.07	0.14	1.00	2299	2583

Draws were sampled using `sample(hmc)`. For each parameter, Bulk_ESS and Tail_ESS are effective sample size measures, and Rhat is the potential scale reduction factor on split chains (at convergence, Rhat = 1).

Hierarchický model problému s nadhodnocováním variance neřeší, je však dalším logickým krokem při tvorbě modelu.

Obrázek 5.3

Posteriorní predikce (tmavě) vs. reálná data (světlé sloupce)



5.4 Model 4: Conway-Maxwell Poisson (COMP)

Tento model byl pokus o řešení nadhodnoceného rozptylu u Poissonovy regrese, avšak se nepodařilo ho dobře parametrizovat a byl tedy vyřazen.

5.5 Model 5: Reziduály smyček

Do modelu byly přidány reziduály počtu smyček po OLS regresi na počet cest. Tento výpočet reziduálů je pouze aproximace, jelikož nezohledňuje celou nejistotu posteriorní distribuce reziduálů, ale pouze jejich OLS odhad. Je tedy možné nadhodnocení predikčních schopností modelu.

$$\begin{aligned}y_i &\sim \text{ZTP}(\lambda_i) \\ \log \lambda_i &= \beta_0 + \beta_p(p_i - \bar{p}) + \beta_t(t_i - \bar{t}) + \beta_{lr} \cdot lr_i \\ \beta_0 &\sim \text{Normal}(\log \bar{p}, 0.2) \\ \beta_p &\sim \text{Normal}(0.1, 0.2) \\ \beta_t &\sim \text{Normal}(0, 0.1) \\ \beta_{lr} &\sim \text{Normal}(0.01, 0.05) \\ \sigma_{\text{id}} &\sim \text{Student-t}(3, 0, 0.1)\end{aligned}$$

5.5.1 Implikace priorů

Prior pro β_0 (průměr lineárního prediktoru) je vycentrovaný na logaritmu zaokrouhleného průměru počtu cest v datech. Tento prior je agnostický vůči směru efektu a naznačuje lineární vztah.

Prior pro β_p je mírně pozitivní, jelikož očekáváme vyšší odhad počtu cest se zvyšujícím se reálným počtem cest.


Prior pro β_{lr} je vycentrovaný na nule. Je totiž možné, že se zvyšujícím se časem lidé spočítají více cest, ale také že kvůli delší rozvaze nenechají zmást vyšší hustotou a počtem smyček.

Prior β_{lr} je vycentrovaný na nule. Dopředu neočekáváme směr efektu reziduálů smyček po kontrole počtu cest. Priorní distribuce pro hyperparametry (σ_{id}) nechávají místo pro individuální rozdíly i v extrémech.

Reziduály smyček lze interpretovat jako (standardizovaný) počet smyček vyšší (nebo menší), než by v grafu predikoval počet cest. Interpretace jejich koeficientů je tedy efekt “nadbytečných” smyček na odhadovaný počet cest.

Obrázek 5.4

Očekávaný odhad a priori (Model 5)



Tabulka 5.1

Očekávaný odhad a priori podle počtu cest

p2	epred	.lower	.upper
1	3.16	1.10	9.11
2	3.32	1.33	8.09
3	3.51	1.59	7.63
4	3.73	1.75	8.06
5	3.95	1.72	8.97
6	4.17	1.61	10.73
7	4.40	1.47	13.42


Tabulka 5.2

Očekávaný odhad a priori podle doby prezentace

t2	epred	.lower	.upper
1 s	3.72	1.38	10.16
3 s	3.71	1.55	9.05
5 s	3.70	1.38	9.99

Obrázek 5.5

Priorní predikce odpovědí (Model 5)



Tabulka 5.3


Parametry pátého modelu

variable	mean	sd	q5	q95	rhat	ess_bulk	ess_tail
b_Intercept	0.90	0.06	0.82	1.02	1	2956	2324
b_p	0.36	0.06	0.26	0.45	1	2848	3364
b_t	0.05	0.05	-0.03	0.13	1	4035	3955
b_lr	0.20	0.05	0.11	0.28	1	5178	3969
sd_id__Intercept	0.10	0.06	0.02	0.21	1	2552	2683
sd_id__p	0.10	0.06	0.04	0.20	1	2947	3340
sd_id__t	0.09	0.05	0.03	0.18	1	2501	1899
sd_id__lr	0.06	0.05	0.00	0.16	1	3411	3523

5.5.2 Fit


Obrázek 5.6

Prior (šedě) vs. posterior (modře)



Obrázek 5.7

Analýza citlivosti prioru – fixed effects




Tabulka 5.4

Analýza citlivosti prioru

variable	prior	likelihood	diagnosis
b_Intercept	0.06	0.60	potential prior-data conflict
b_p	0.05	0.38	potential prior-data conflict
b_t	0.05	0.11	potential prior-data conflict
b_lr	0.11	0.33	potential prior-data conflict
sd_id__Intercept	0.15	0.56	potential prior-data conflict
sd_id__p	0.17	0.35	potential prior-data conflict
sd_id__t	0.18	0.33	potential prior-data conflict
sd_id__lr	0.11	0.32	potential prior-data conflict


Obrázek 5.8

Analýza citlivosti prioru – individuální odchylky




Obrázek 5.9

Priorní (šedě) vs. posteriorní predikce (modře) počtu cest



Obrázek 5.10

Očekávání modelu s intervaly



Jak lze vidět na Obrázek 5.9 a Obrázek 5.10, model vnímá jednoznačně rostoucí trend v počtu cest.

Se zvyšujícím se časem se dle modelu zvyšuje i rozptyl, což jde proti naší původní hypotéze o vyšší přesnosti při delším časovém úseku.

Naši druhou hypotézu, vyšší počet smyšek vede


Tabulka 5.5

Porovnání predikčních schopností modelu pomocí LOO

model	elpd_diff	se_diff
fit5	0.0	0.00
fit3	-25.1	4.65
fit2	-48.9	6.30
fit1	-394.2	12.07

Obrázek 5.11

Posteriorní predikce (tmavě) vs. reálná data (světlé sloupce)



5.6 PSIS-LOO

Při porovnání predikční validity modelů pomocí aproximální leave-one-out cross validace dosáhl model č. 5 výrazně lepších výsledků než ostatní modely.

6 Limitace

- Interval 5 s pro odpověď zkresluje efekt doby prezentace stimulů.
- Nedostatek dat pro komplexnější model odlišující různé strategie (hádání vs. počítání).